Филиал Московского Государственного Университета имени М.В. Ломоносова в г. Ташкенте

Факультет прикладной математики и информатики

Кафедра прикладной математики и информатики

Мурадасилов Руслан Серверович

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

на тему: «EM-алгоритм и его применение в статистических задачах»

по направлению 01.03.02 «Прикладная математика и информатика»

ВКР рассмотрена и рекомендована к защите

зав. кафедрой «ПМиИ», к.ф.-м.н., доцент_____ Строгалов А. С.

Научный руководитель:

к.ф.-м.н. _____ Абдушукуров А. А.

«____»_____ 2021 г.

Ташкент 2021

Аннотация

В данной работе рассматривается EM-алгоритм и его применение в статистических задачах.

В первой части работы описан сам EM-алгоритм, его свойства и модификации. Вторая часть работы представляет собой исследование по применению EM-алгоритма к цензурированной выборке на языке программирования Python с помощью модуля GaussianMixture библиотеки Scikit-Learn и модулем Stats библиотеки SciPy.

Ключевые слова: цензурированная выборка, EM-алгоритм, GaussianMixture

Abstract

This paper is devoted to EM-algorithm and its application in statistical problems.

The first part of the paper describes EM-algorithm, its properties and modifications. The second part of the paper represents a research on application of EM-algorithm to censored data on Python programming language using the GaussianMixture module of Scikit-Learn library and Stats module of SciPy library.

Keywords: censored data, EM-algorithm, GaussianMixture

Содержание

1 Введение

EM-алгоритм в математической статистике используется для нахождения оценок максимального правдоподобия параметров вероятностной модели, в случае, когда модель зависит от некоторых скрытых данных. Как правило, EM-алгоритм применяется при решении задач двух типов.

К первому типу относятся задачи с *действительно* неполными данными, когда некоторые статистические данные отсутствуют в силу каких-либо причин. Ко второму же типу можно отнести задачи, в которых удобно вводить скрытые переменные для упрощения подсчета функции правдоподобия. Примером такой задачи может служить кластеризация.

В данной работе приведено описание EM-алгоритма и его свойства, а также предложен пример с его применением к задаче первого типа.

В первой части работы дан теоретический материал, в котором подробно изложены E-шаг и M-шаг от общих случаев к частным.

Вторая часть работы посвящена применению EM-алгоритма с использованием модуля GaussianMixture библиотеки Scikit-Learn на языке Python. В первую очередь были сгенерированы разные выборки с помощью модуля Stats библиотеки SciPy, на основе которых была проведена проверка работоспособности и степень точности оценки алгоритма на данных разных распределений. Далее алгоритм был применен к цензурированной выборке, предварительно предобратонной с помощью оценки $FnRR$, предложенной Абдушукуровым А. А.

2 Историческая часть вопроса

Одним из первых EM-алгоритм был предложен McKendrick (1926) для медицинских приложений. Затем после довольно большого перерыва эта идея вновь возникла в работах Healy and Westmacott (1956), Шлезингера (1965, 1968), Day (1969), Wolfe (1970), а затем развита и систематически исследована в работе Dempster, Laird and Rubin (1977) [1]. Само название *EM-алгоритм* было предложено в работе [1], в которой показана высокая общность алгоритма. Возможно, поэтому зарубежные источники традиционно ссылаются на эту статью, как на первую работу по EM-алгоритму.

Основные свойства EM-алгоритма описаны еще в работе Шлезингера (1965) [2]. Позднее в работах Dempster, Laird and Rubin (1977), Everitt and Hand (1981), Wu (1983), Boyles (1983), Redner and Walker (1984) эти свойства были передоказаны и развиты.

Литература по EM-алгоритму и его применениям к решению задач из конкретных областей обширна. Среди них можно выделить книги, посвященные собственно EM-алгоритму Литтла и Рубина (1991), McLachlan and Krishnan (1997), книги, в которых EM-алгоритму уделено значительное место Айвазяна и др. (1989) [3], Tanner (1993), а также двух обстоятельных работ Bilmes (1998) и Figueiredo (2004).

3 Основные результаты

3.1 Описание EM-алгоритма

EM-алгоритм состоит из итерационного повторения двух шагов. На E-шаге вычисляется ожидаемое значение (expectation) вектора скрытых переменных G по текущему приближению вектора параметров Θ. На M-шаге решается задача максимизации правдоподобия (maximization) и находится следующее приближение вектора Θ по текущим значениям векторов G и Θ.

Пусть $X = (X_1, ..., X_n)$ — n случайных независимых наблюдений размерности m, k — количество распределений в смеси, называемых кластерами,

$$p(x) = \sum_{j=1}^{k} w_j p_j(x), \quad \sum_{i=1}^{k} w_j = 1, \quad w_j \geq 0,$$

где $p_j(x)$ — функция правдоподобия j-ой компоненты смеси, w_j — её априорная вероятность. Задача: зная $X,\ p(x),\ k$ оценить неизвестные параметры $\Theta = (w_1, ..., w_k,\ \theta_1, ..., \theta_k)$.

Общий случай.

E-шаг:

$$p(x, \theta_j) = p(x)P(\theta_j \mid x) = w_j p_j(x)$$

$$g_{ij} := P(\theta_j \mid x) = \frac{w_j p_j(x_i)}{\sum_{s=1}^{k} w_s p_s(x_i)}, \quad \sum_{j=1}^{k} g_{ij} = 1, \quad i = 1, ..., m$$

— неизвестная апостериорная вероятность того, что объект x_i получен из j-ой компоненты смеси.

M-шаг:

Будем максимизировать логарифм полного правдоподобия:

$$Q(\Theta) = ln \prod_{i=1}^{m} p(x_i) = \sum_{i=1}^{m} ln \sum_{j=1}^{k} w_j p_j(x_i) \to \max_{\Theta}$$

Решая оптимизационную задачу Лагранжа с ограничением на сумму w_j,

находим:

$$w_j = \frac{1}{m}\sum_{i=1}^{m} g_{ij}, \quad j = 1, ..., k$$

$$\theta_j = \underset{\theta}{argmax} \sum_{i=1}^{m} g_{ij} ln\varphi(x_i, \theta), \quad j = 1, ..., k$$

Частные случаи.

1. $m = 1$ — одномерные наблюдения, т. е. точки, $k = 2$ — два гауссовых распределения a и b с неизвестными параметрами (μ, σ^2).

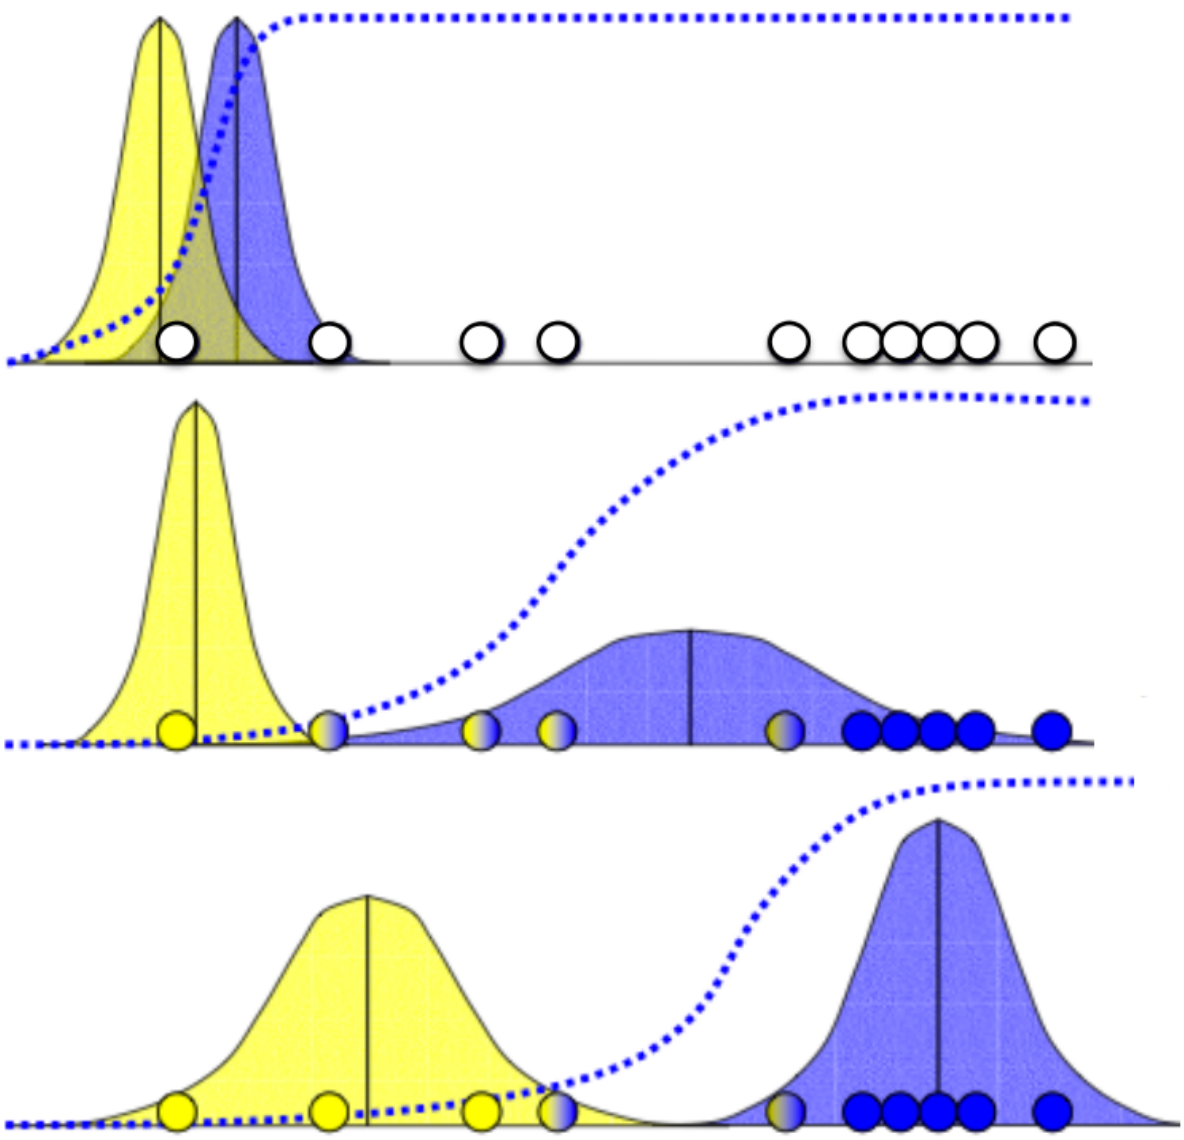

Рис. 1

Оценка этих параметров была бы тривиальной, если бы мы знали, какому из распределений принадлежит каждое из наблюдений:

$$\mu_a = \frac{x_1 + x_2 + ... + x_{n_a}}{n_a},\ \ \sigma_a^2 = \frac{(x_1 - \mu_a) + (x_2 - \mu_a) + ... + (x_{n_a} - \mu_a)}{n_a}$$

Аналогично для (μ_b, σ_b^2).

И, наоборот, зная параметры (μ, σ^2) мы определяем, какова вероятность принадлежности наблюдения этому распределению по формуле Байеса:

$$b_i = P(b \mid x_i) = \frac{P(x_i \mid b)P(b)}{P(x_i \mid b)P(b) + P(x_i \mid a)P(a)},\ a_i = P(a \mid x_i) = 1 - b_i$$

где $P(x_i \mid b) = \frac{1}{\sqrt{2\pi\sigma_b^2}} e^{-\frac{(x_i - \mu_b)^2}{2\sigma_b^2}}$.

Следовательно, в нашей задаче необходимо знать параметры (μ, σ^2) для оценки принадлежности наблюдений распределениям и в то же время знать распределение для оценки параметров. Тут и приходит на помощь EM-алгоритм (Рис. 1):

(a) возьмем случайным образом два гауссовых распределения (μ_a, σ_a^2) и (μ_b, σ_b^2);

(b) **E-шаг:** вычислим a_i и b_i для каждого наблюдения;

(c) **M-шаг:** пересчитываем (μ_a, σ_a^2) и (μ_b, σ_b^2) по формулам:

$$\mu_a = \frac{a_1 x_1 + ... + a_n x_n}{a_1 + ... + a_n},\quad \sigma_a^2 = \frac{a_1(x_1 - \mu_a) + ... + a_n(x_n - \mu_a)}{a_1 + ... + a_n}$$

Аналогично для (μ_b, σ_b^2);

(d) продолжаем итеративно вплоть до сходимости;

Также в M-шаге можно было пересчитывать априорные вероятности $P(b) = \frac{b_1 + ... + b_n}{n}$ и $P(a) = 1 - P(b)$.

2. $m > 1,\ k > 2$.

$$P(c) = \frac{1}{n} \sum_{i=1}^{n} P(c \mid \vec{x_i}) \text{ для кластера c}$$

$$\mu_{c,j} = \sum_{i=1}^{n} \left(\frac{P\left(c \mid \vec{x}_i\right)}{nP(c)} \right) x_{i,j}$$

$$\left(\Sigma_c\right)_{j,k} = \sum_{i=1}^{n} \left(\frac{P\left(c \mid \vec{x}_i\right)}{nP(c)} \right) \left(x_{i,j} - \mu_{c,j}\right) \left(x_{i,k} - \mu_{c,k}\right)$$

$$P(c \mid \vec{x}_i) = \frac{P(\vec{x}_i \mid c)P(c)}{\sum_{c'=1}^{k} P(\vec{x}_i \mid c')P(c')}$$

$$P\left(\vec{x}_i \mid c\right) = \frac{1}{\sqrt{2\pi \left|\Sigma_c\right|}} \exp(-\frac{1}{2} \underbrace{\left(\vec{x}_i - \vec{\mu}_c\right)^T \Sigma_c^{-1} \left(\vec{x}_i - \vec{\mu}_c\right)}_{\sum_{j=1}^{d} \sum_{k=1}^{d} (x_{i,j} - \mu_{c,j}) \left(\Sigma_c^{-1}\right)_{jk} (x_{i,k} - \mu_{c,k})})$$

3.2 Применение EM-алгоритма

В данной работе EM-алгоритм представлен классом GaussianMixture [6], предложенной библиотекой scikit-learn. Этот класс позволяет оценивать параметры гауссовских распределений.

Метод fit этого класса оценивает параметры модели с помощью EM-алгоритма. Метод fit итерируется между E-шагом и M-шагом указанное количество раз до тех пор, пока изменение правдоподобия или нижней границы не станет меньше некоторого числа. В противном случае возникнет сообщение о том, что метод не сходится.

При создании экземпляра класса указывается количество компонент смеси.

3.2.1 Проверка работоспособности GaussianMixture

С помощью модуля stats [7] библиотеки Scipy сгенерированы выборки разных распределений.

Для ясности введём следующие обозначения:

- cdf — cumulative distribution function — функция распределения;
- pdf — probability density function — плотность вероятности распределения;
- std — standard deviation of the distribution — среднеквадратическое отклонение распределения.

Проверка работоспособности проводится в несколько этапов.

1. Напомним формулу гауссовского распределения

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}},$$

где параметр μ — математическое ожидание и σ среднеквадратическое отклонение распределения. Квадрат среднеквадратического отклонения, σ^2, называется дисперсией.

Генерирование одного одномерного гауссовского распределения (Рис. 2):

```
mu = 0
variance = 1
sigma = math.sqrt(variance)
x = np.linspace(mu - 3*sigma, mu + 3*sigma, 100)
data = norm.pdf(x, mu, sigma)
```

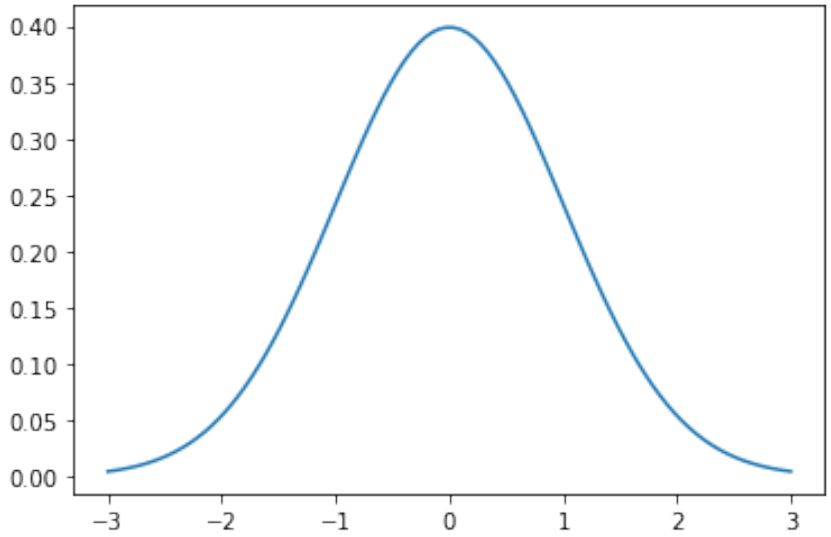

Рис. 2

Проверка оценки параметров соответствующей выборки с помощью GaussianMixtureModel:

```
k = 1
model = gmm(n_components=k, covariance_type='full')
model.fit(data)
```

Вывод программы:

```
data_mean: 0.1645975096425618
data_covariance: 0.13947206450268224
model_mean: 0.16459751
model_covariance: 0.13947565
```

В результате видим, что оценка параметров GaussianMixtureModel в точности совпадает с реальными параметрами.

2. Генерирование двух одномерных гауссовских распределений (Рис. 3):

```
mu_1 = 2
variance_1 = 4
sigma_1 = math.sqrt(variance_1)

mu_2 = 10
variance_2 = 1
sigma_2 = math.sqrt(variance_2)

x_1 = np.linspace(mu_1 - 3*sigma_1, mu_1 + 3*sigma_1, 100)
x_2 = np.linspace(mu_2 - 3*sigma_2, mu_2 + 3*sigma_2, 100)
data_1 = norm.pdf(x_1, mu_1, sigma_1)
data_2 = norm.pdf(x_2, mu_2, sigma_2)
```

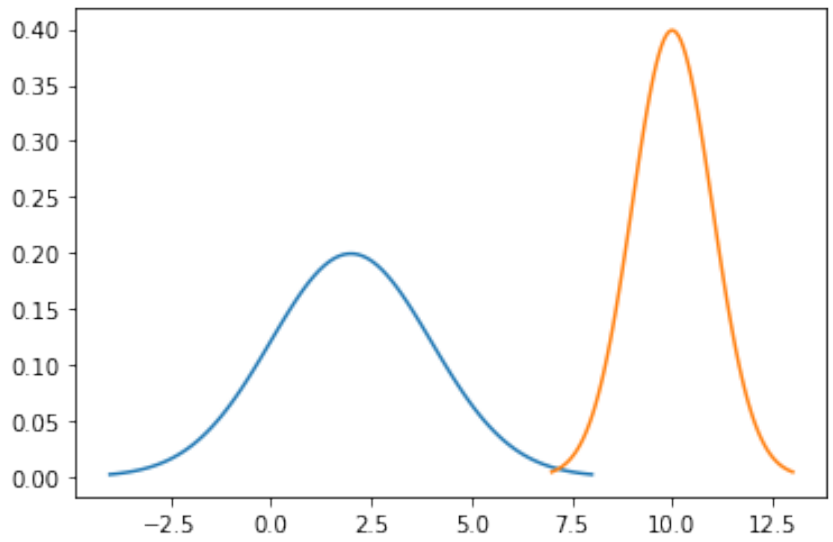

Рис. 3

Генерирование одной выборки для двух распределений и проверка оценки её параметров с помощью GaussianMixtureModel:

```
new_data = np.concatenate((data_1, data_2), axis=0)
np.random.shuffle(new_data)

k = 2
model = gmm(
        n_components=k,
        max_iter=1000,
        covariance_type='full'
)
model.fit(new_data)
```

Вывод программы:

```
data_mean_1: 0.0822987548212809
data_covariance_1: 0.06973603225134112
data_mean_2: 0.16459750964256176
data_covariance_2: 0.1394720645026822

model_mean_1: 0.01832714
model_covariance_1: 0.01409637
model_mean_2: 0.18062076
model_covariance_2: 0.10954001
```

Здесь во время многократных экспериментов точность результата варьировалась в зависимости от исходных распределений.

3. Генерирование одного двумерного гауссовского распределения (Рис. 4):

```
x = np.linspace(0, 10, 100)
y = np.linspace(10, 20, 100)
X, Y = np.meshgrid(x, y)
```

```
mu_x = np.mean(x)
sigma_x = np.std(x)
mu_y = np.mean(y)
sigma_y = np.std(y)
norm = multivariate_normal(
        [mu_x, mu_y],
        [[sigma_x, 0],
        [0, sigma_y]]
)

pos = np.empty(X.shape + (2,))
pos[:, :, 0] = X
pos[:, :, 1] = Y
data = norm.pdf(pos)
```

Проверка оценки параметров соответствующей выборки с помощью GaussianMixtureModel:

```
k = 2
model = gmm(
        n_components=k,
        max_iter=10000,
        covariance_type='full'
)
model.fit(new_data)
```

Вывод программы:

```
data_mean_x: 5.0
data_covariance_x: 2.9157646512850626
data_mean_y: 15.0
```

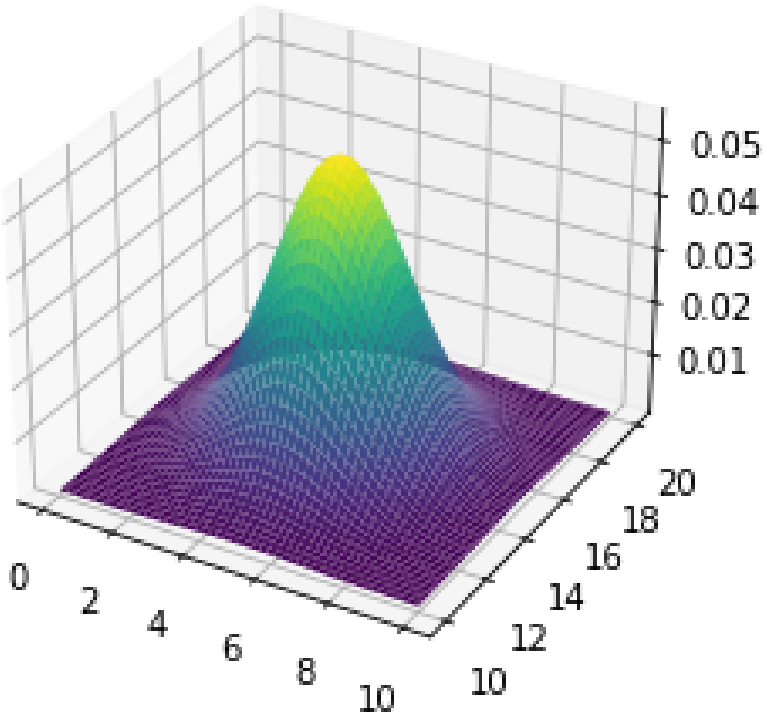

Рис. 4

```
data_covariance_y: 2.9157646512850626

model_mean_x: 5.12451189
model_covariance_x: 3.16980297
model_mean_y: 14.7726552
model_covariance_y: 3.22703713
```

Здесь во время многократных экспериментов точность результата варьировалась в зависимости от исходных распределений.

4. Напомним формулу равномерного распределения

$$p(x) = \frac{1}{b-a},$$

принимающая значения $p(x)$ в промежутке $[a, b)$, и ноль — вне промежутка.

Генерирование одного одномерного равномерного распределения (Рис. 5):

```
a = 0
b = 5
size = 100
uni = uniform(loc=a, scale=b)
x = np.linspace(uni.ppf(0), uni.ppf(1), size)
data = uni.pdf(x)
```

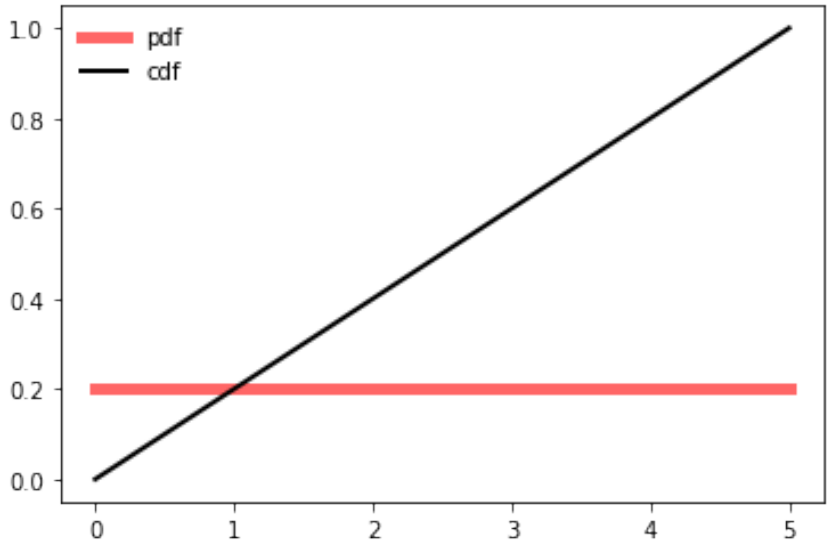

Рис. 5

Проверка оценки параметров соответствующей выборки с помощью GaussianMixtureModel:

```
k = 1
model = gmm(n_components=k, covariance_type='full')
model.fit(data)
```

Вывод программы:

```
data_mean: 0.19999999999999996
data_covariance: 5.551115123125783e-17
model_mean: 0.2
model_covariance: 0.001
```

В результате видим, что оценка параметров равномерной выборки с помощью GaussianMixtureModel далека от истинного значения.

3.2.2 Применение EM-алгоритма к цензурированной выборке

Дана выборка объема $n = 97$ вида $\{(z_{(i)}, \delta_{(i)}),\ i = \overline{1,n}\}$ (Рис. 6):

(777;1), (781;0), (843;0), (866;0), (869;1), (872;1), (876;1), (893;1), (894;1), (895;0), (898;1), (906;0), (907;1), (909;1), (911;1), (911;0), (914;0), (927;1), (932;1), (936;0), (940;0), (942,5;0), (943;0), (945;1), (945;0), (948;1), (951;0), (953;0), (956;0), (957;1), (957;0), (959;0), (960;0), (966;1), (966;0), (969;1), (970;0), (971;1), (972;0), (973;0), (977;0), (983;1), (984;0), (985;1), (989;1), (992,5;1), (993;1), (996;1), (998;1), (1001;0), (1002;0), (1005;0), (1006;0), (1009;1), (1011,5;1), (1012;1), (1012;0), (1013;0), (1015;0), (1016;0), (1018;0), (1022;1), (1023;0), (1025;1), (1027;0), (1029;1), (1031;1), (1031;0), (1031,5;0), (1033;1), (1036;1), (1043;1), (1043;0), (1044;1), (1044;0), (1045;0), (1047;0), (1053;1), (1055;1), (1058;0), (1059;1), (1060;1), (1060;0), (1064;0), (1070;0), (1073;0), (1080;1), (1085;1), (1093;0), (1093,5;1), (1094;1), (1106;0), (1107;0), (1118;0), (1128;1), (1139;1), (1153;0).

Данные представлены в месяцах, причем число 1 в парах означает нецензурирование (т.е. смерть), а 0 - цензурирование. При этом 46 человек умерли с начала открытия центра в 1964 году по 1 июля 1975 года ко дню сбора данных. Это нецензурированные данные. Из остальных 51 человек 5 были выписаны из центра, а 46 ещё были живы к 1 июля 1975 года. Это цензурировананные данные.

Построим оценку, предложенную к.ф.-м.н. А. А. Абдушукуровым,

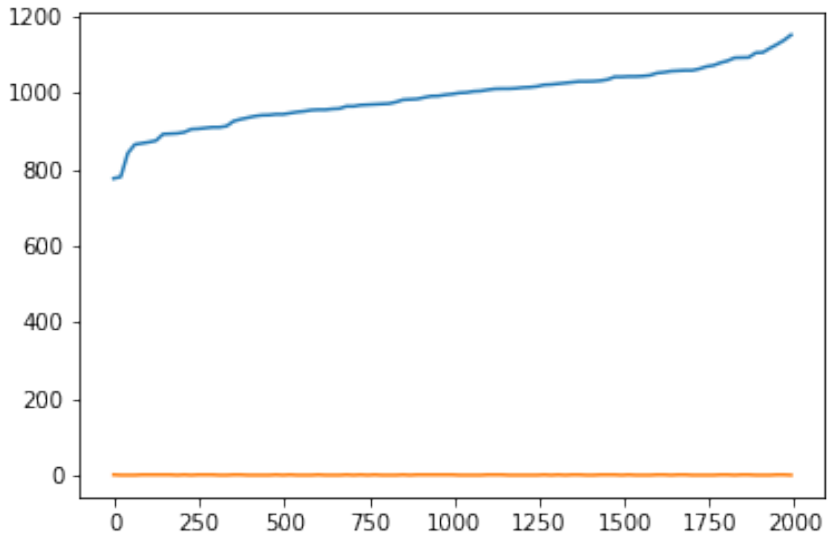

Рис. 6

по следующим формулам:

$$F_n^{RR}(x) = 1 - (1 - H_n(x))^{\frac{\Lambda_{1n}(x)}{\Lambda_n(x)}} =$$

$$= \begin{cases} 0, & x < z_{(1)} \\ 1 - (1 - \frac{k}{n})^{\frac{\Lambda_{1n}(x)}{\Lambda_n(x)}}, & z_{(k)} \le x < z_{(k+1)}, k = \overline{1,n} \\ 1, & x \ge z_{(n)} \end{cases},$$

где

$$1 - H_n(x) = \frac{1}{n} \sum_{j=1}^{n} I(z_{(j)} > x),$$

$$\Lambda_{1n}(x) = \int_{-\infty}^{x} \frac{dH_{1n}(u)}{1 - H_{1n}(u-)} =$$

$$= \frac{1}{n} \sum_{j=1}^{n} \frac{\delta_{(j)} I(z_{(j)} \le x)}{\frac{1}{n} \sum_{i=1}^{n} I(z_{(i)} \ge z_{(j)})} = \sum_{j=1}^{n} \frac{\delta_{(j)} I(z_{(j)} \le x)}{\sum_{i=1}^{n} I(z_{(i)} \ge z_{(j)})},$$

$$\Lambda_n(x) = \int_{-\infty}^{x} \frac{dH_n(u)}{1 - H_n(u-)} = \sum_{j=1}^{n} \frac{I(z_{(j)} \le x)}{\sum_{i=1}^{n} I(z_{(i)} \ge z_{(j)})}.$$

Приведём код программы, которая реализует вышеизложенные формулы и строит оценку F_n^{RR} (Рис. 7):

```
def one_minus_H_n(x, data):
    n = len(data)
    result = 0
    for i in range(n):
        result += 1 if data[i][0] > x else 0
    result /= n
    return result

def Lambda_1n(x, data):
    n = len(data)
    result = 0
    numerator = 0
    denominator = 0
    for i in range(n):
        denominator = 0
        numerator = data[i][1] * (1 if data[i][0] <= x else 0)
        for j in range(n):
            denominator += (1 if data[j][0] >= data[i][0] else 0)
        result += numerator / denominator
    return result

def Lambda_n(x, data):
    n = len(data)
    result = 0
    numerator = 0
    denominator = 0
    for i in range(n):
        denominator = 0
        numerator = 1 if data[i][0] <= x else 0
        for j in range(n):
            denominator += (1 if data[j][0] >= data[i][0] else 0)
        result += numerator / denominator
    return result
```

```
def FnRR(x, data):
    result = 1 - one_minus_H_n(x, data)**(Lambda_1n(x, data) /
                                          Lambda_n(x, data))
    return result
```

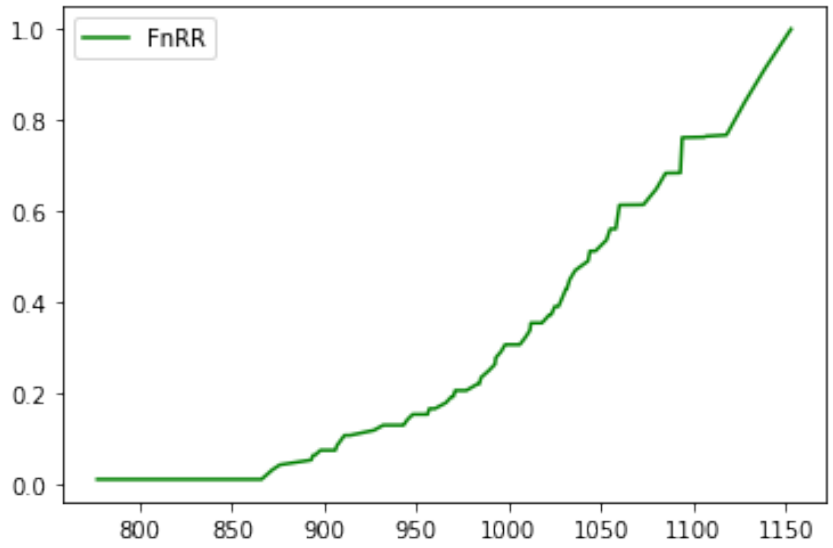

Рис. 7

По следующим формулам вычислим математическое ожидание и дисперсию для цензурированной выборки:

$$\hat{\mu}_n = \int_{z(1)}^{z(n)} t dF_n^{RR}(t) = \sum_{i=1}^{n} z_{(i)} \Delta F_n^{RR}(z_i)$$

$$\hat{\sigma}_n^2 = \int_{z(1)}^{z(n)} (t - \hat{\mu}_n)^2 dF_n^{RR}(t) = \sum_{i=1}^{n} (z_{(i)} - \hat{\mu}_n)^2 \Delta F_n^{RR}(z_i),$$

где $\Delta F_n^{RR}(z_i)$ — скачок функции.

Приведём код программы, которая реализует вышеизложенные формулы в одной функции:

```
def calculate_mu_and_sigma(z, data):
n = len(data)
mu = z[0] * FnRR(z[0], data)
```

```
for i in range(2, n):
    mu += z[i] * (FnRR(z[i], data) - FnRR(z[i-1], data))
variance = (z[0] - mu) ** 2 * FnRR(z[0], data)
for i in range(2, n):
    variance += (z[i] - mu) ** 2 * (FnRR(z[i], data)
                                    - FnRR(z[i-1], data))
sigma = sqrt(variance)
return mu, sigma
```

Далее центрируем и нормируем исходные данные (Рис. 8):

```
z = [data[i][0] for i in range(97)]
mu, sigma = calculate_mu_and_sigma(z, data)

data_processed = (data[:, 0] - mu) / sigma
data_processed = np.c_[data_processed, data[:, 1]]

z = [data_processed[i][0] for i in range(97)]
mu, sigma = calculate_mu_and_sigma(z, data_processed)
```

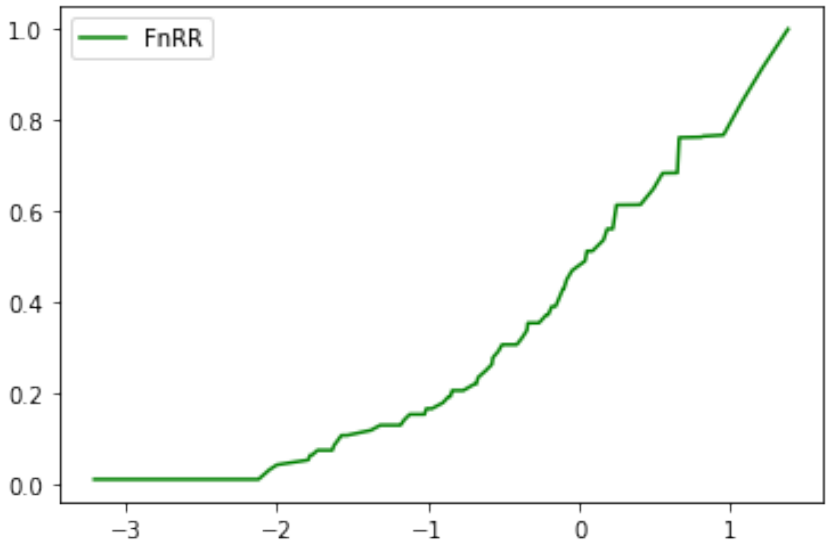

Рис. 8

Вывод программы:

```
mu_before: 1039.7833741995091
sigma_before: 81.9647172814403
mu_after: 3.5417227168543786e-06
sigma_after: 0.9999999999937279
```

Проверка оценки параметров выборки, состоящей из компоненты z, с помощью GaussianMixtureModel:

```
k = 1
model = GMM(
    n_components=k,
    max_iter=10000,
    covariance_type='full'
)
model.fit(data_processed)
```

Вывод программы:

```
data_mean: 3.5417227168543786e-06
data_covariance: 0.9999999999937279
model_mean: -0.58832044
model_covariance: 0.8946689
```

В результате видим, что оценка параметров цензурированной выборки после центрирования и нормирования с помощью GaussianMixtureModel очень близка к истинному значению.

4 Заключение

В данной работе было собрано методическое пособие по знакомству с EM-алгоритмом на примере смеси гауссовых распределений. Было дано описание самого алгоритма, которое позволит быстро ознакомиться с теоритической частью EM-алгоритма.

Также был выполнен следующий прикладной вклад. Во-первых, было наглядно продемонстрирована генерация выборок разных распределений и исследованы результаты способностей GaussianMixture оценивать параметры таких выборок. Во-вторых, был сделан новый шаг по вычислению математического ожидания и дисперсии цензурированных выборок на основе оценки Абдушукурова А. А. и предложен способ по применению EM-алгоритма к таким выборкам на реальных данных.

В дальнейшем предполагается увеличение компонент смеси распределений и расширение семейства самих распределений, подаваемых на вход EM-алгоритму. К примеру, разработка GeneralMixture, позволяющей оценивать параметры любого семейства распределений.

Автор выражает благодарность А. А. Абдушукурову за научное руководство.

5 Список литературы

[1] Dempster A. P., Laird N. M., Rubin D. B. Maximum likelihood from incomplete data via the EM algorithm // J. of the Royal Statistical Society, Series B. — 1977. —no. 34. — Pp. 1–38.

[2] Шлезингер М. И. О самопроизвольном различении образов // Читающие автоматы. — Киев, Наукова думка, 1965. — Pp. 38–45

[3] Айвазян С. А., Бухштабер В. М., Енюков И. С., Мешалкин Л. Д. Прикладная статистика: классификация и снижение размерности. — М.: Финансы и статистика, 19

[4] В. Ю. Королёв. ЕМ-алгоритм, его модификации и их применение к задаче разделения смесей вероятностных рспределений

[5] К. В. Воронцов. Лекции по статистическим (байесовским) алгоритмам классификации

[6] Документация GaussianMixture
`https://scikit-learn.org/stable/modules/generated/sklearn.mixture.GaussianMixture.html#sklearn.mixture.GaussianMixture`

[7] Документация к модулю stats библиотеки Scipy
`https://docs.scipy.org/doc/scipy/reference/tutorial/stats.html`